

Estadística en Analítica

2023-2

Pablo A. Saldarriaga
psaldar2@eafit.edu.co

UNIVERSIDAD
EAFIT

Programación del curso

Evaluación:

- ✓ Parcial **(25%)**
- ✓ Seguimiento **(40%)**
 - ✓ Taller 1 **(20%)**
 - ✓ Taller 2 **(20%)**
- ✓ Proyecto Integrador **(35%)**

Sesiones de Clase

Fecha	Comentario
Octubre 20	Inicio del curso
Octubre 21	
Octubre 27	
Octubre 28	
Noviembre 3	Entrega Taller 1
Noviembre 4	
Noviembre 10	
Noviembre 11	Ultima clase teorica
Noviembre 17	Parcial y Entrega Taller 2

Texto guía: *The Elements of Statistical Learning* (2009)

Contenido del Curso

0. Preliminares y pre-procesamiento de datos

- ✓ Repaso de probabilidad
- ✓ Variables aleatorias
- ✓ Inferencia Estadística (estimadores y propiedades)
- ✓ Intervalos de confianza y pruebas de hipótesis
- ✓ Estadísticos univariados y multivariados


1. Técnicas Supervisadas

- ✓ Modelos de regresión
- ✓ Modelos de clasificación
- ✓ Estrategia de regularización
- ✓ Métricas de desempeño de regresión y clasificación
- ✓ Sesgo VS Varianza
- ✓ Validación Cruzada

2. Técnicas No Supervisadas

- ✓ Reducción de Dimensionalidad
 - ✓ PCA
 - ✓ Umap
- ✓ Análisis de cluster
 - ✓ Métodos jerárquicos
 - ✓ Métodos no jerárquicos
 - ✓ Selección de cantidad de grupos
 - ✓ Métricas de validación de cluster

(Cross Industry Standard Process for Data Mining)



Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. & Wirth, R. Step-by-step data mining guide (2000).

Preliminares: Probabilidad e Inferencia

Probabilidad

Qué tan frecuente ocurre algo

de registros que cumplen la condición en estudio

¡Enfoque frecuentista!

$$\frac{\# \text{ Casos Posibles}}{\# \text{ Casos Totales}}$$

Tamaño de la muestra

Probabilidad Condicional

*Es el cálculo de una probabilidad
acotando el espacio muestral que se
considera*



$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

	Ocurre B	No ocurre B
Ocurre A	N1	N2
No ocurre A	N3	N4

$$\frac{N1 / (N1 + N2 + N3 + N4)}{(N1 + N3) / (N1 + N2 + N3 + N4)}$$

$$\frac{N1}{N1 + N3}$$

Probabilidad Condicional

	Credito Rechazado	Credito Aprobado	Totales
Cliente Nuevo	210.000	140.000	350.000
Cliente Recurrente	1.500	28.500	30.000
Totales	211.500	168.500	380.000

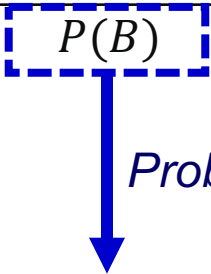
Probabilidad Total

Sean A_1, A_2, \dots, A_n eventos excluyentes, tal que $\bigcup_{i=1}^n A_i = S$, además B es un evento de S

$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

Teorema de Bayes

$$P(A_j|B) = \frac{P(B|A_j)P(A_j)}{P(B)}$$

 *Probabilidad Total*

$$P(A_j|B) = \frac{P(B|A_j)P(A_j)}{\sum_{i=1}^n P(A_i)P(B|A_i)}$$

Variables Aleatorias

Una variable aleatoria X es una función real definida en espacio de probabilidad asociado a un experimento aleatorio

$$X: \Omega \rightarrow \mathbb{R}$$

Función de densidad y distribución

Para cualquier distribución de probabilidad discreta, lo siguiente debe ser verdadero:

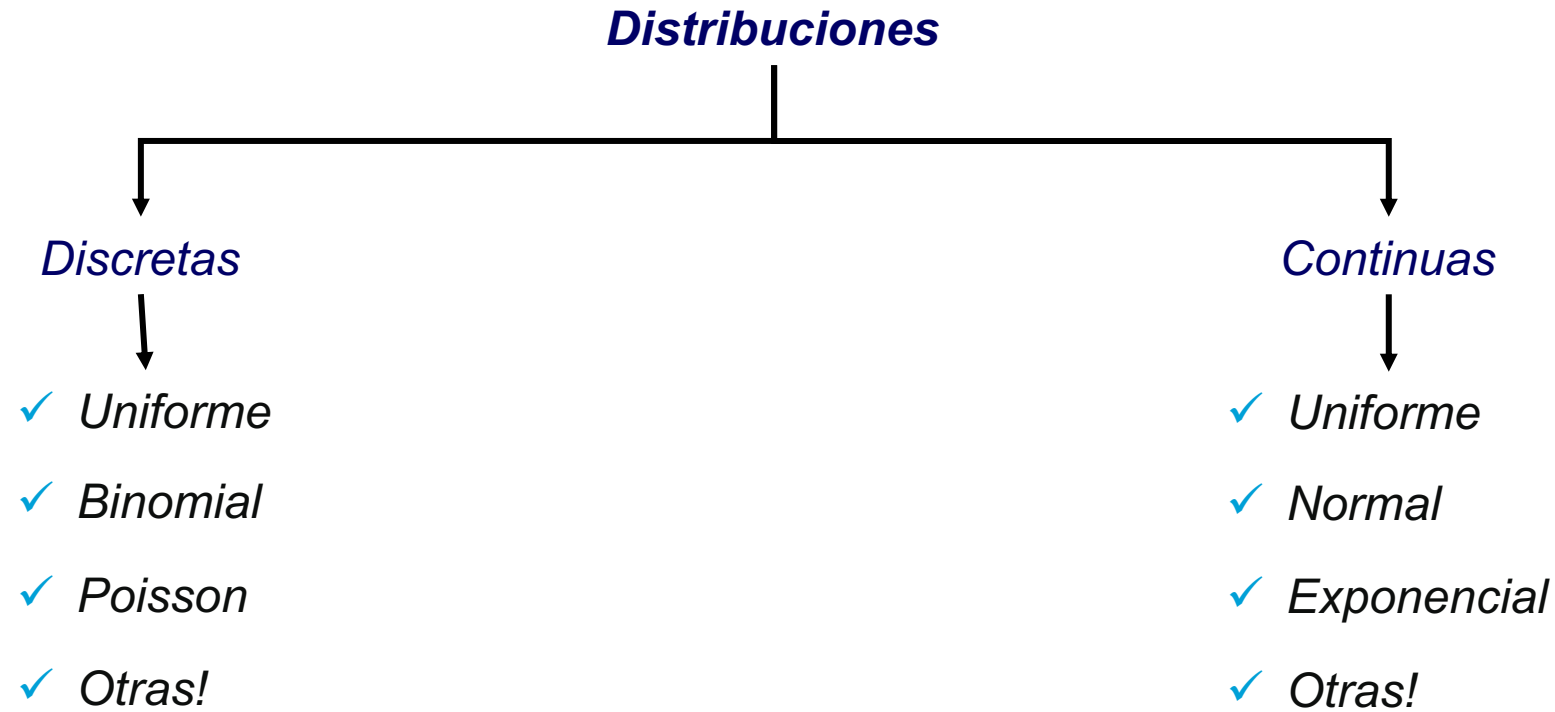
1. $0 \leq p(y) \leq 1$ para toda y .
2. $\sum_y p(y) = 1$, donde la sumatoria es para todos los valores de y con probabilidad diferente de cero.

Propiedades de una función de densidad Si $f(y)$ es una función de densidad para una variable aleatoria continua, entonces

1. $f(y) \geq 0$ para toda y , $-\infty < y < \infty$.
2. $\int_{-\infty}^{\infty} f(y) dy = 1$.

Las probabilidades puntuales son 0

Distribuciones de Probabilidad



Función Generadora de Momentos

Promedio

$$\mu = E[X]$$

Varianza

$$\sigma^2 = E[X^2] - (E[X])^2$$

$$M_x(t) = E[e^{tx}]$$

$$M_x(t) = \sum_{x=1}^{\infty} e^{tx} P(X = x)$$

$$M_x(t) = \int_{-\infty}^{\infty} e^{tx} f(x) dx$$

Dist. Discreta: Uniforme

$$X \sim \text{Unif}\{x_1, x_2, \dots, x_n\}$$

$$P(X = x) = \begin{cases} \frac{1}{n} & \text{si } x = x_1, x_2, \dots, x_n \\ 0 & \text{En otro caso} \end{cases}$$

$$\mu = \frac{n+1}{2}$$

$$\sigma^2 = \frac{n^2-1}{12}$$

Dist. Discreta: Binomial

$$X \sim \text{Bin}(n, p)$$

$$P(X = x) = \begin{cases} \frac{n!}{x! (n-x)!} p^x (1-p)^{n-x} & \text{si } x = x_1, x_2, \dots, x_2 \\ 0 & \text{En otro caso} \end{cases}$$

$$\mu = np$$

$$\sigma^2 = np(1-p)$$

Modela la cantidad de éxitos en n sucesos

Dist. Discreta: Poisson

$$X \sim \text{Poisson}(\lambda)$$

$$P(X = x) = \begin{cases} \frac{\lambda^x e^{-\lambda}}{x!} & \text{si } x = 0, 1, \dots \\ 0 & \text{En otro caso} \end{cases}$$

$$\mu = \lambda$$

$$\sigma^2 = \lambda$$

Modela la cantidad de eventos que ocurren en un periodo de tiempo

Dist. Continua: Uniforme

$$X \sim \text{Unif}(a, b)$$

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } a < x < b \\ 0 & \text{En otro caso} \end{cases}$$

$$\mu = \frac{a+b}{2}$$

$$\sigma^2 = \frac{(b-a)^2}{12}$$

Dist. Continua: Normal

$$X \sim N(\mu, \sigma)$$

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x-\mu)^2}{2\sigma^2}}$$

$$\mu = \mu$$

$$\sigma^2 = \sigma^2$$

Dist. Continua: Exponencial

$$X \sim \text{Exp}(\lambda)$$


$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{si } x > 0 \\ 0 & \text{En otro caso} \end{cases}$$

$$\mu = \frac{1}{\lambda}$$

$$\sigma^2 = \frac{1}{\lambda^2}$$

Modela tiempos de espera para la ocurrencia de eventos

De binomial a Normal



**Inspira
Crea
Transforma**

www.eafit.edu.co

VIGILADA | MINEPUCACIÓN

**UNIVERSIDAD
EAFIT**